Лабораторна робота № 3

Діагностика шкал вимірювання

Курс СК26 «Інтелектуальний аналіз та візуалізація даних»

Тривалість: 2 год аудиторно + 3 год самостійно · **Оцінка:** 4 бали **Файли:** `Ковід_дані_навчальні.xlsx` , `ЛР3_помилковий_аналіз.ipynb`

Шкала вимірювання визначає, які операції над змінною взагалі мають сенс. Комп'ютер цього не знає: він порахує середнє від номера телефону й не поскаржиться. Знати має вимірювач.

У цій роботі ви складаєте **паспорт восьми змінних** свого варіанта, показуєте на власних даних, які статистики для них недопустимі, і виправляєте чужий аналіз, де таких помилок десять.

In [25]:
```
ПРІЗВИЩЕ_ІМЯ = 'Бугай Софія'      # напишіть тут своє прізвище та ім'я
ГРУПА        = 'ШІ-34'
НОМЕР        = 2       # ваш номер за списком групи (1–30)

assert ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР, 'Заповніть три поля вище'
assert 1 <= НОМЕР <= 30, 'Номер має бути від 1 до 30'
```

In [26]:
```
import json
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import warnings
warnings.filterwarnings('ignore')

pd.set_option('display.max_colwidth', 60)

ВАРІАНТИ = json.load(open('lr3_variants_student.json', encoding='utf-8'))
В = ВАРІАНТИ[НОМЕР - 1]

print('=' * 74)
print(f'ВАРІАНТ {В["варіант"]}   ·   {ПРІЗВИЩЕ_ІМЯ}   ·   {ГРУПА}')
print('=' * 74)
print()
print('Ваші вісім стовпців:')
for i, c in enumerate(В['стовпці'], 1):
    print(f'   {i}. {c}')
print()
print('Ваша пара для аналізу зв’язку:', ' та '.join(В['пара']))
print()
```

```
print('Ваше додаткове питання:')
print('  ', B['питання'])
```

```
================================================================================
ВАРІАНТ 2   ·   Бугай Софія   ·   ШІ-34
================================================================================

Ваші вісім стовпців:
   1. Телефон
   2. Супутній
   3. ЛН
   4. Дата розтину
   5. КТ
   6. Фібрин1
   7. Сечов2
   8. ФЕРИТ1

Ваша пара для аналізу зв’язку: ЛН та помер/жив

Ваше додаткове питання:
   Стовпець «АТ пост» містить значення на кшталт «140/100». Запропонуйте три способи
перетворити його на числові ознаки та обґрунтуйте, який із них візьмете в модель.
```

In [27]:
```
ФАЙЛ = 'Ковід_дані_навчальні.xlsx'
df = pd.read_excel(ФАЙЛ, sheet_name='Лист1', engine='openpyxl')
МОЇ = B['стовпці']

print('Розмір набору:', df.shape)
df[МОЇ].head(8)
```

```
Розмір набору: (121, 77)
```

Out[27]:

	Телефон	Супутній	ЛН	Дата розтину	КТ	Фібрин1	Сечов2	ФЕРИТ1
0	0958469788 дружина Ганна	ІХС, КС, СН1, НВ ФК2	III-IV	2022-03-11	20-30%	4	6.5	NaN
1	0671778486, 0994887663 дружина Оксана	ЦД, II тип	II-III	NaT	30-35%	5	4	839.0
2	0958768045, чоловік Степан 0951784726	ІХС. КС, ГХІІ, ГЛШ СНІІа, порушення толерантності до глю...	II	NaT	70-80%	5.29	10.1	NaN
3	0959819331. дочка Валентина 0960845205	ЦД, II тип, ІХС, Диф кардіоск, стенокар напруги, синусов...	III-IV	NaT	0.8	2.5	12.5	NaN
4	0952294866, дочка Дарина 0678360161	ІХС ДК ГХІІ-ІІІ СНІІа ГЛШст3	II-III	NaT	NaN	4.29	7.4	NaN
5	0959922983 сестра Софія	ІХС ДК ГХІІ ГЛШ СНІІ ФК2, ЦД II	II-III	2021-12-26	30-40%	5	21.4	NaN
6	0998073702, дружина Наталія 0998382226	ІХС ДК ГХ IIа ФК3, ЦД вперше виявлений	II-III	NaT	60-65%	3.24	6.1	NaN
7	0637258771, син Сергій 0968413301	ІХС ДК ГХІІ ГЛШ СНІІа ФК3, полімедик алергія,ерозивий г/...	I	NaT	до 17%	5.04	7.6	NaN

Етап 1. Паспорт змінних

Для кожного з восьми стовпців визначте шкалу вимірювання. Спирайтеся не на тип даних у pandas, а на **зміст величини**: що означають її значення і які порівняння між ними мають сенс.

Нагадування:

Шкала	Ознака
Номінальна	значення можна лише порівняти на рівність

Шкала	Ознака
Порядкова	є природний порядок, але відстані між сусідніми рівнями невідомі
Інтервальна	різниці мають сенс, нуль умовний
Відношень	є природний нуль, відношення мають сенс
Абсолютна	природні і нуль, і одиниця вимірювання

Окремо позначайте **ідентифікатори** — значення, що не є величиною взагалі (номер історії хвороби, прізвище, телефон).

In [28]:
```
# Спершу подивіться, що каже pandas — і не довіряйте йому
df[МОЇ].info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 121 entries, 0 to 120
Data columns (total 8 columns):
 #   Column        Non-Null Count  Dtype         
---  ------        --------------  -----         
 0   Телефон       120 non-null    object        
 1   Супутній      115 non-null    object        
 2   ЛН            121 non-null    object        
 3   Дата розтину  61 non-null     datetime64[ns]
 4   КТ            44 non-null     object        
 5   Фібрин1       115 non-null    object        
 6   Сечов2        102 non-null    object        
 7   ФЕРИТ1        2 non-null      float64       
dtypes: datetime64[ns](1), float64(1), object(6)
memory usage: 7.7+ KB
```

In [29]:
```
# Далі — що є всередині насправді
for c in МОЇ:
    з = df[c].dropna()
    типи = ', '.join(f'{t.__name__}×{n}' for t, n in з.map(type).value_counts().ite
    print(f'--- {c}')
    print(f'    непорожніх {len(з)} з {len(df)} | унікальних {з.nunique()} | типи:
    print(f'    приклади: {[repr(v) for v in з.unique()[:4]]}')
    print()
```

```
--- Телефон
    непорожніх 120 з 121 | унікальних 120 | типи: str×97, int×23
    приклади: ["'0958469788 дружина Ганна'", "'0671778486, 0994887663 дружина Оксан
а'", "'0958768045, чоловік Степан 0951784726'", "'0959819331. дочка Валентина 096084
5205'"]

--- Супутній
    непорожніх 115 з 121 | унікальних 91 | типи: str×115
    приклади: ["'ІХС, КС, СН1, НВ ФК2'", "'ЦД, ІІ тип'", "'ІХС. КС, ГХІІ, ГЛШ СНІІа,
порушення толерантності до глюкози'", "'ЦД, ІІ тип, ІХС, Диф кардіоск, стенокар напр
уги, синусова тахік, ГХІІ, СНІІв '"]

--- ЛН
    непорожніх 121 з 121 | унікальних 6 | типи: str×121
    приклади: ["'III-IV'", "'II-III'", "'II'", "'I'"]

--- Дата розтину
    непорожніх 61 з 121 | унікальних 50 | типи: Timestamp×61
    приклади: ["Timestamp('2022-03-11 00:00:00')", "Timestamp('2021-12-26 00:00:0
0')", "Timestamp('2021-11-19 00:00:00')", "Timestamp('2022-05-13 00:00:00')"]

--- КТ
    непорожніх 44 з 121 | унікальних 26 | типи: float×27, str×17
    приклади: ["'20-30%'", "'30-35%'", "'70-80%'", '0.8']

--- Фібрин1
    непорожніх 115 з 121 | унікальних 87 | типи: float×93, int×21, str×1
    приклади: ['4', '5', '5.29', '2.5']

--- Сечов2
    непорожніх 102 з 121 | унікальних 66 | типи: float×79, int×22, str×1
    приклади: ['6.5', '4', '10.1', '12.5']

--- ФЕРИТ1
    непорожніх 2 з 121 | унікальних 2 | типи: float×2
    приклади: ['np.float64(839.0)', 'np.float64(271.1)']
```

Заповніть паспорт

Для кожного стовпця вкажіть шкалу та **обґрунтування** — одне речення про те, чому саме ця шкала. Обґрунтування оцінюється, назва шкали сама по собі — ні.

In [30]:
```python
ПАСПОРТ = {
    # 'назва стовпця': ('шкала', 'обґрунтування однією фразою'),
    'Телефон': ('ідентифікатор', 'Це не величина, а будь-які дії між ними не несуть
    'Супутній': ('номінальна', 'Це вільний текст, знначення яких можна лише порівня
    'ЛН': ('порядкова', 'Порядок ступенів природний, але відстані між ними не визна
    'Дата розтину': ('інтервальна', 'Різниця між датами має сенс, але нульова дата
    'КТ': ('відношень', 'Нуль природний, а відношення між величинами мають сенс'),
    'Фібрин1': ('відношень', 'Лабораторна концентрація -- нуль означає, що речовини
    'Сечов2': ('відношень', 'Лабораторна концентрація -- нуль означає, що речовини
    'ФЕРИТ1': ('відношень', 'Лабораторна концентрація -- нуль означає, що речовини
}
```

```
for c in МОЇ:
    ПАСПОРТ.setdefault(c, ('', ''))

паспорт_df = pd.DataFrame(
    [(c, ПАСПОРТ[c][0], ПАСПОРТ[c][1]) for c in МОЇ],
    columns=['Стовпець', 'Шкала', 'Обґрунтування'])
паспорт_df
```

Out[30]:

	Стовпець	Шкала	Обґрунтування
0	Телефон	ідентифікатор	Це не величина, а будь-які дії між ними не несуть важлив...
1	Супутній	номінальна	Це вільний текст, знначення яких можна лише порівняти на...
2	ЛН	порядкова	Порядок ступенів природний, але відстані між ними не виз...
3	Дата розтину	інтервальна	Різниця між датами має сенс, але нульова дата умовна
4	КТ	відношень	Нуль природний, а відношення між величинами мають сенс
5	Фібрин1	відношень	Лабораторна концентрація -- нуль означає, що речовини не...
6	Сечов2	відношень	Лабораторна концентрація -- нуль означає, що речовини не...
7	ФЕРИТ1	відношень	Лабораторна концентрація -- нуль означає, що речовини не...

In [31]:
```
# --- САМОПЕРЕВІРКА 1 ---
ДОПУСТИМІ = {'номінальна', 'порядкова', 'інтервальна', 'відношень',
             'абсолютна', 'ідентифікатор'}
for c in МОЇ:
    ш, об = ПАСПОРТ[c]
    assert ш.strip().lower() in ДОПУСТИМІ, f'{c}: шкалу «{ш}» не розпізнано'
    assert len(об.strip()) >= 25, f'{c}: обґрунтування закоротке'
print('Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.')
```

```
Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.
```

Етап 2. Допустимі статистики

Для кожного стовпця обчисліть **тільки те, що дозволяє його шкала**.

- номінальна та ідентифікатор — мода, частоти
- порядкова — додатково медіана та квантилі
- інтервальна — додатково середнє та стандартне відхилення
- відношень і абсолютна — усе, зокрема коефіцієнт варіації

Якщо для стовпця не можна порахувати нічого, крім частот, — так і напишіть.

In [32]:
```
for v in df['ЛН'].dropna().unique():
    print(repr(v), [hex(ord(ch)) for ch in v])
```

```
'III-IV' ['0x406', '0x406', '0x406', '0x2d', '0x49', '0x56']
'II-III' ['0x406', '0x406', '0x2d', '0x406', '0x406', '0x406']
'II' ['0x406', '0x406']
'I' ['0x406']
'III' ['0x406', '0x406', '0x406']
'I-II' ['0x406', '0x2d', '0x406', '0x406']
```

In [33]:
```
def нормалізуй_лн(s):
    return (str(s).strip()
            .replace('\u0406', 'I')
            # .replace('\u0456', 'I')
            .replace('–', '-').replace('—', '-')
            .replace(' ', '').upper())

ПОРЯДОК = {'ЛН': ['I', 'I-II', 'II', 'II-III', 'III', 'III-IV']}  # звірте з кроком

def допустима_статистика(стовпець, шкала):
    """Повертає словник статистик, дозволених для цієї шкали."""
    з = df[стовпець].dropna()
    р = {'непорожніх': len(з), 'унікальних': з.nunique()}
    ш = шкала.strip().lower()

    р['частоти'] = з.value_counts().to_dict()
    if ш in ('ідентифікатор',):
        return р
    р['мода'] = з.mode().tolist()
    if ш == 'номінальна':
        return р

    if ш == 'порядкова':
        cats = ПОРЯДОК[стовпець]
        норм = з.map(нормалізуй_лн)
        невідомі = sorted(set(норм) - set(cats))
        if невідомі:
            р['немає в ПОРЯДОК'] = невідомі
        норм = норм[норм.isin(cats)]
        if норм.empty if False else норм.empty:
            р[''] = 'жодне значення не збіглося з ПОРЯДОК'
            return р
        коди = норм.map({c: i for i, c in enumerate(cats)})
        for q in (0.25, 0.5, 0.75):
            р[f'квантиль {q}'] = cats[int(np.quantile(коди, q, method='lower'))]
        return р

    if pd.api.types.is_datetime64_any_dtype(з):
        чис = з
    else:
        чис = pd.to_numeric(з, errors='coerce').dropna()
        відкинуто = len(з) - len(чис)
        if відкинуто:
```

```
            p['не-числових відкинуто'] = відкинуто

    p['медіана'] = чис.median()
    p['q25'], p['q75'] = чис.quantile(0.25), чис.quantile(0.75)
    p['середнє'] = чис.mean()
    p['ст. відхилення'] = чис.std()
    if ш == 'інтервальна':
        return p

    p['коеф. варіації'] = чис.std() / чис.mean()
    return p


for c in МОЇ:
    print(f'--- {c}  ({ПАСПОРТ[c][0]})')
    print('   ', допустима_статистика(c, ПАСПОРТ[c][0]))
    print()
```

```
--- Телефон  (ідентифікатор)
    {'непорожніх': 120, 'унікальних': 120, 'частоти': {'0958469788 дружина Ганна':
1, '0671778486, 0994887663 дружина Оксана': 1, '0958768045, чоловік Степан 095178472
6': 1, '0959819331. дочка Валентина 0960845205': 1, '0952294866, дочка Дарина 067836
0161': 1, '0959922983 сестра Софія': 1, '0998073702, дружина Наталія 0998382226': 1,
'0637258771, син Сергій 0968413301': 1, '0963194893, сестра Катерина 0964948214': 1,
'0635244106 син Микола': 1, 504118955: 1, 955939761: 1, 635060454: 1, '0679110285 по
друга Зоряна': 1, '0993228088, син Степан 0954230048': 1, 961280845: 1, 990370382:
1, 'син владислав 0997879432': 1, 'син Ярослав 0638421083': 1, '0638440932, дружина
Ганна 0634845263': 1, 688280258: 1, 'син Володимир 0679932157': 1, '0675795111, дочк
а 0954432568': 1, '0966327926, син 0635154742': 1, 'дружина Юлія 0950856517': 1, '06
75996775, син Сергій 0500314503': 1, '0953924196, чол.Володимир 0998982104': 1, '095
4754072, дочка Христина 0507547354': 1, 506188479: 1, 'дочка Тетяна 0638861930': 1,
'0995568983, чол Сергій 0679822290': 1, '0672022697, невістка Тетяна 0960438581': 1,
'0964502831, друж Марія 0956323373': 1, '0951331159, друж Марина 0992123636': 1, '06
37212835, дружт 0956990854': 1, '0960187916. чол Володимир 0999797802': 1, 'дочка Те
тяна 0961524735': 1, '0953197967, друж 0960736087': 1, '0962819539, друж Людмила 050
8276116': 1, '0503817805, друж Вікторія 0997803704': 1, 'дочка Уляна 0998288983': 1,
'дочка Людмила 0958179223': 1, 'син Юрій 0968372527': 1, 'брат Олег 0999043163': 1,
'чол Володимир 0503729871': 1, 'дочка Олена 0676079113': 1, 'син ОЛлександр063521980
3': 1, 'дочка Юлія 0638639848': 1, 'син Богдан 0632692767': 1, 'дружина Надія0964985
568': 1, 'дочка Людмила 0503327967': 1, 'невістка Ганна0965816354': 1, 677611387: 1,
'0671076177 дочка Дарина': 1, 'син 0951520299': 1, 503516199: 1, 964398286: 1, 96746
4397: 1, 634193039: 1, 991566979: 1, 686795965: 1, 637056709: 1, 680156464: 1, 50132
0598: 1, 969042163: 1, 681960278: 1, '0638296017невістка': 1, 992041263: 1, 67524013
7: 1, 680591483: 1, 968181378: 1, '0673257192 подруга': 1, '0637613414 дочка Софія':
1, '0960053051 дочка Наталія': 1, '0997605538 син Микола': 1, '072761514 дочка Катер
ина': 1, '06762394249 брат Роман': 1, '0969974535 дочка Юлія': 1, '0634104751 внучка
Альона ': 1, '0962359534син Віктор': 1, '0962446026чоловік Василь': 1, '0992007009не
вістка Катерина': 1, '0504887781 Марина': 1, '0670383004 друж Марія': 1, '0505529301
сестра Лариса': 1, '0962992398 внук Влад': 1, '0961299914 внучка': 1, '0953516768 си
н Григорій': 1, 'плем альона 0954366282': 1, 'дочка Ганна 0994262837': 1, 'дочка Тет
яна 0968704151': 1, 'дружина Христина 0993782760': 1, 'дочка галина 0507002238': 1,
'невістка Дарина 0635013510': 1, 'син Віктор 0995165850': 1, 'дружина Катерина 05030
22502': 1, 'дружина Марія 0963419082': 1, 'родич Роман 0998637877': 1, 'внук Михайло
0632764129': 1, 'дружина Оксана 0679360550': 1, 'невістка Тетяна 0678792687': 1, 'пл
емінниця Софія 0952056832': 1, 'син Ярослав 0960788203': 1, 'внук Євген 0951100989':
1, 'син Дмитро 0996929844': 1, 'внучка Альона 0636643231': 1, 'сестра Юлія 47967252
1': 1, 'дочка Людмила 0672713831': 1, 'дочка Валентина 0507425657': 1, 'подруга Ольг
а 0996450114': 1, 'дочка Ганна 0954851481': 1, 'дочка Ганна 0958195961': 1, 'дочка Д
арина 0505753921': 1, 'дружина Оксана 0990499531': 1, 'дружина Христина 0965424744':
1, 'син Василь 0992528456': 1, 'син Юрій 0506942669': 1, 'дружинаРуслана 099074777
6': 1, 'невістка Олена 186134069': 1, 'дочка Лариса 0997567817': 1}}

--- Супутній  (номінальна)
    {'непорожніх': 115, 'унікальних': 91, 'частоти': {'ІХС ДК ГХст2': 7, 'ІХС.ДК. ГХ
ІІ': 5, 'ІХС ДК ГХст2.': 4, 'ІХС.ДК .Атеросклероз аорти. Первинно зморщені нирки':
3, 'ІХС ДК ГХст3': 2, 'ІХС ДК ГХст2. ЦД': 2, 'ІХС.ДК. ГХ ІІ. ЦД ': 2, 'ІХС.ДК. ХОЗЛ.
ГХ ІІ': 2, 'Хрон гастродуоденіт': 2, 'ІХС ДК ГХст2 СНІІа': 2, 'ІХС.ДК. ЦД. Атероскле
роз аорти': 2, 'ІХС ДК ГХ ІІ СНІІа ФК3': 2, 'ІХС ДК ГЛШ ст2 СН ІІА ': 2, 'ІХС ДК Піс
ляпневмонічний дифузний базальний фіброз легень': 1, 'ГХ 2-3ст, ЦД вперше виявлени
й': 1, 'ІХС ДК': 1, 'ІХС. Фібриляція передсердь': 1, 'ІХС Стенокар напруги, тахісист
варіан, ГХст3': 1, 'ІХС, КС, СН1, НВ ФК2': 1, 'ЦД, ІІ тип, ІХС, Диф кардіоск, стенок
ар напруги, синусова тахік, ГХІІ, СНІІв ': 1, 'ІХС ДК ГХІІ-ІІІ СНІІа ГЛШст3': 1, 'ІХ
С ДК ГХІІ ГЛШ СНІІ ФК2, ЦД ІІ': 1, 'ІХС ДК ГХ ІІа ФК3, ЦД вперше виявлений': 1, 'ІХС
ДК ГХІІ ГЛШ СНІІа ФК3, полімедик алергія,ерозивий г/дуоденіт': 1, 'ІХС ДК ГХ2 ГЛШст2
```

КВР3 СН2 ФК3, ЦД2, Cr прав молоч залози після промен терап': 1, 'ЦД, II тип': 1, 'IX С. КС, ГХII, ГЛШ СНIIа, порушення толерантності до глюкози': 1, 'IXC ДК ГХст2 ГЛШст2 Опасистість2ст': 1, 'ЦД 2тип, IXC ДК ГХст2 ГЛШ СН2а Фібр передсер': 1, 'IXC Післяінф ар кардіоск, ГХст3, ГЛШ СН2а': 1, 'IXC ДК СН2ст': 1, 'ЦД тип 2, IXC ДК СНст1 ФК II I': 1, 'ЦЖ II тип': 1, 'IXC ДК ГХст2 ГЛШст3 СН2': 1, 'ЦД тип 2, IXC ДК ГХст2 ГЛШ СНI Iа': 1, 'ЦД': 1, 'IXC Післяінфар кардіоск, ГХст3, фібриляція передсер,шлун екстрасис ит аритмія': 1, 'IXC ДК . ГХ III': 1, 'ЦД тип II, IXC ДК ГХ2 ГЛШст2 СН2а': 1, 'ЦД ти п II вперше вияв IXC ДК ГХ2 ГЛШст2 СН2а': 1, 'IXC Стабільна стенок напруги, ГХст3, Г ЛШст2': 1, 'ГХст2ГЛШст2 Медикаментозна алергія': 1, 'IXC ДК Стенок напруги ГХст2а ЦД Iітип': 1, 'IXC.ДК. Шл екстрасит ': 1, 'IXC.ДК. ГХ III. Гіпотериоз': 1, 'IXC.Стенока рдія напруги': 1, 'IXC.ДК. ХОЗЛ': 1, 'IXC.ДК. ': 1, 'Хрон. Ероз. гастродуоденіт': 1, 'хр.панкреатит. Диф нетокс зоб.ХОЗЛ': 1, 'IXC.ДК. ГХ II. Міокардит .Аритмія': 1, 'Хр.тонзиліт ': 1, 'IXC.ДК. ГХ II.Анемія середн.важк': 1, 'IXC ДК ГХст2 СН1 ': 1, 'ЦД тип II вперше вияв IXC ДК ГХ2 ГЛШст2 СН2а. Хрон нирк недос IIст, хрон пієлонефри т': 1, 'ЦД тип II, IXC ДК Стенокардія напруги ГХст2': 1, 'ГХ 2 ГЛШст2 СН I ': 1, "IX С.ДК СНмт2а Анемія важк ст нез'яс генезу.Хрон холицистит": 1, 'IXC Стабільна стенок напруги, ': 1, 'IXC.ДК. Хронічна анемія': 1, 'IXC.ДК. ГХ III': 1, 'IXC.ДК. ГХ II. ЦД .Рак лівої молочної з-зи. Хронічна анемія': 1, 'IXC.ДК. ГХ II. ЦД .Рак молочної з -зи. Маніакал-депрес синдром': 1, 'IXC.ДК. ХОЗЛ. Остеоартроз': 1, 'Хр.Гастроентероко літ ': 1, 'IXC.ДК.': 1, 'IXC.ДК. ЦД. Рак лівої молочної з-зи. ': 1, 'IXC ДК ГХ II СН IIа ФК 3': 1, 'IXC ДК ГХ II СН IIа ФК 3-4 Церебральний атеросклероз': 1, 'IXC ДК СН IIа ФК 3': 1, 'IXC ДК ГЛШ ЦД II тип. ': 1, 'IXC ДК ГХ III СН IIA ЦД II тип': 1, 'IX С.ДК. ГХ III Гепатит': 1, 'IXC.ДК. ЦД. ГХ III. ': 1, 'IXC': 1, 'IXC.ДК. ЦД. Атероскл ероз аорти.Дифузний ліпоматоз (ожиріння 3)': 1, 'IXC.ДК. Волога гангрена обох стоп і гомілок': 1, 'IXC ДК ГХст2. Опасистість III': 1, 'IXC.ДК.ГХ ст2 .Атеросклероз аорт и': 1, 'IXC ДК ГХст2.Емфізема легень': 1, 'IXC ДК ГХст2.Емфізема легень.Атеросклероз аорти. Первинно зморщені нирки': 1, 'Облітеруючий атеросклероз ниж кінц.оклюзія стег но-підколінного сегменту зліва,ішемія кінц. Хр бронхіт, пієлонефрит. Гепатит С': 1, 'Цукровий діабет Iітип , Опасистість III': 1, 'IXC ДК СН IIа Атеросклероз аорти та в інцевих судин. ': 1, 'IXC ДК ГХ Ii СН Iіа Емфізема легень Хрон бронхіт': 1, 'Бронхіа льна астма. Емфізема легень. Дифузний пневмосклероз': 1, 'IXC ДК ГХст2.Атеросклероз аорти. Первинно зморщені нирки': 1, 'Хронічний холецисто-панкреатит': 1, 'IXC ДК СН IIа Атеросклероз аорти та вінцевих судин. Кардіомегалія': 1, 'IXC ДК СН IIа Атероск лероз аорти та вінцевих судин. Рак лівої молочної залози та сечового міхура': 1, 'Анемія хронічного захворювання важкого ступеня ': 1}, 'мода': ['IXC ДК ГХст2']}

--- ЛН (порядкова)
    {'непорожніх': 121, 'унікальних': 6, 'частоти': {'II-III': 59, 'II': 21, 'III': 17, 'I': 12, 'I-II': 9, 'III-IV': 3}, 'мода': ['II-III'], 'квантиль 0.25': 'II', 'кв антиль 0.5': 'II-III', 'квантиль 0.75': 'II-III'}

--- Дата розтину (інтервальна)
    {'непорожніх': 61, 'унікальних': 50, 'частоти': {Timestamp('2022-06-07 00:00:0 0'): 3, Timestamp('2022-04-27 00:00:00'): 2, Timestamp('2022-04-07 00:00:00'): 2, Ti mestamp('2022-04-13 00:00:00'): 2, Timestamp('2022-04-30 00:00:00'): 2, Timestamp('2 022-05-03 00:00:00'): 2, Timestamp('2022-04-10 00:00:00'): 2, Timestamp('2022-05-22 00:00:00'): 2, Timestamp('2022-05-06 00:00:00'): 2, Timestamp('2022-03-30 00:00:0 0'): 2, Timestamp('2022-03-29 00:00:00'): 1, Timestamp('2022-04-26 00:00:00'): 1, Ti mestamp('2021-12-26 00:00:00'): 1, Timestamp('2022-03-11 00:00:00'): 1, Timestamp('2 021-11-19 00:00:00'): 1, Timestamp('2022-05-13 00:00:00'): 1, Timestamp('2022-06-18 00:00:00'): 1, Timestamp('2022-04-09 00:00:00'): 1, Timestamp('2022-05-01 00:00:0 0'): 1, Timestamp('2022-04-20 00:00:00'): 1, Timestamp('2022-04-05 00:00:00'): 1, Ti mestamp('2022-04-24 00:00:00'): 1, Timestamp('2022-04-15 00:00:00'): 1, Timestamp('2 022-03-24 00:00:00'): 1, Timestamp('2022-03-05 00:00:00'): 1, Timestamp('2022-04-06 00:00:00'): 1, Timestamp('2022-06-04 00:00:00'): 1, Timestamp('2022-03-02 00:00:0 0'): 1, Timestamp('2021-01-06 00:00:00'): 1, Timestamp('2022-04-29 00:00:00'): 1, Ti

mestamp('2022-02-10 00:00:00'): 1, Timestamp('2022-02-25 00:00:00'): 1, Timestamp('2
022-02-03 00:00:00'): 1, Timestamp('2022-06-22 00:00:00'): 1, Timestamp('2022-02-18
00:00:00'): 1, Timestamp('2022-02-24 00:00:00'): 1, Timestamp('2022-01-19 00:00:0
0'): 1, Timestamp('2022-05-29 00:00:00'): 1, Timestamp('2022-04-21 00:00:00'): 1, Ti
mestamp('2022-06-03 00:00:00'): 1, Timestamp('2022-05-18 00:00:00'): 1, Timestamp('2
022-05-14 00:00:00'): 1, Timestamp('2022-05-17 00:00:00'): 1, Timestamp('2022-05-21
00:00:00'): 1, Timestamp('2022-04-25 00:00:00'): 1, Timestamp('2022-03-15 00:00:0
0'): 1, Timestamp('2022-02-15 00:00:00'): 1, Timestamp('2022-04-23 00:00:00'): 1, Ti
mestamp('2022-05-04 00:00:00'): 1, Timestamp('2022-05-07 00:00:00'): 1}, 'мода': [Ti
mestamp('2022-06-07 00:00:00')], 'медіана': Timestamp('2022-04-23 00:00:00'), 'q25':
Timestamp('2022-03-29 00:00:00'), 'q75': Timestamp('2022-05-07 00:00:00'), 'середн
є': Timestamp('2022-04-06 13:22:37.377049088'), 'ст. відхилення': Timedelta('72 days
13:34:38.466302692')}

--- КТ (відношень)
    {'непорожніх': 44, 'унікальних': 26, 'частоти': {0.3: 6, 0.25: 5, 0.7: 3, 0.8:
3, 0.5: 2, '70-80%': 2, '65-70%': 2, 0.4: 2, '25-30%': 2, '20-30%': 1, 'до 17%': 1,
'60-65%': 1, '30-40%': 1, '30-35%': 1, 0.15: 1, 0.05: 1, 0.08: 1, '25-35 %': 1, '45-
50%': 1, 0.1: 1, '60-70': 1, '40-45%': 1, '50-75%': 1, 0.6: 1, '   ': 1, 0.3
5: 1}, 'мода': [0.3], 'не-числових відкинуто': 17, 'медіана': np.float64(0.3), 'q2
5': np.float64(0.25), 'q75': np.float64(0.55), 'середнє': np.float64(0.3955555555555
556), 'ст. відхилення': np.float64(0.22886565312315255), 'коеф. варіації': np.float6
4(0.5785929432888687)}

--- Фібрин1 (відношень)
    {'непорожніх': 115, 'унікальних': 87, 'частоти': {6: 6, 7: 5, 4: 4, 5: 4, 5.5:
4, 4.41: 2, 3.55: 2, 3.8: 2, 5.02: 2, 4.6: 2, 4.21: 2, 4.99: 2, 3.99: 2, 4.2: 2, 2.9
7: 2, 5.04: 1, 3.24: 1, 4.29: 1, 2.5: 1, 4.8: 1, 3.92: 1, 6.8: 1, 5.29: 1, 7.77: 1,
4.88: 1, 8.36: 1, 6.9: 1, 5.6: 1, 2.8: 1, 2.55: 1, 3.5: 1, 4.66: 1, 5.55: 1, 5.73:
1, 5.43: 1, 5.41: 1, 4.55: 1, 7.16: 1, 3.9: 1, 17.13: 1, 4.74: 1, 3.26: 1, '5.9.':
1, 0.33: 1, 4.77: 1, 8: 1, 9.29: 1, 7.7: 1, 7.1: 1, 3.1: 1, 3.81: 1, 8.6: 1, 4.4: 1,
6.88: 1, 2.6: 1, 3.94: 1, 2.2: 1, 3.93: 1, 7.06: 1, 3.04: 1, 5.07: 1, 7.6: 1, 5.9:
1, 4.48: 1, 2.15: 1, 3.97: 1, 5.01: 1, 6.64: 1, 6.46: 1, 3: 1, 5.2: 1, 5.99: 1, 6.0
7: 1, 2.43: 1, 5.52: 1, 3.17: 1, 4.57: 1, 3.98: 1, 3.32: 1, 4.85: 1, 5.96: 1, 3.64:
1, 7.8: 1, 2.04: 1, 5.7: 1, 6.37: 1, 4.37: 1}, 'мода': [6], 'не-числових відкинуто':
1, 'медіана': np.float64(4.9350000000000005), 'q25': np.float64(3.9475), 'q75': np.f
loat64(6.0), 'середнє': np.float64(5.0548245614035086), 'ст. відхилення': np.float64
(1.9526547540253876), 'коеф. варіації': np.float64(0.38629525719547797)}

--- Сечов2 (відношень)
    {'непорожніх': 102, 'унікальних': 66, 'частоти': {4.9: 4, 5: 4, 4: 3, 6.5: 3, 6.
1: 3, 7.6: 3, 5.5: 3, 10: 3, 7.1: 3, 6.2: 3, 6.7: 2, 6.9: 2, 5.9: 2, 7.7: 2, 6.4: 2,
6.8: 2, 7.3: 2, 9.4: 2, 8.1: 2, 7.2: 2, 8: 2, 11.4: 2, 8.6: 2, 4.6: 2, 14.1: 1, 5.7:
1, 15: 1, 8.2: 1, 12.5: 1, 10.1: 1, 21.4: 1, 11.9: 1, 7.8: 1, 7.4: 1, 12.4: 1, 10.5:
1, 14.2: 1, 4.3: 1, 7: 1, 4.2: 1, 8.4: 1, 3.4: 1, 13.6: 1, 3.9: 1, 11: 1, 5.6: 1, 7
0: 1, 14: 1, 9.7: 1, 116: 1, 19.4: 1, 8.8: 1, 3.7: 1, 10.9: 1, 37: 1, 8.7: 1, 'нема
є': 1, 12.7: 1, 12.6: 1, 9.06: 1, 4.8: 1, 8.3: 1, 9: 1, 13.2: 1, 35: 1, 6: 1}, 'мод
а': [4.9, 5], 'не-числових відкинуто': 1, 'медіана': np.float64(7.3), 'q25': np.floa
t64(5.9), 'q75': np.float64(10.0), 'середнє': np.float64(10.198613861386137), 'ст. в
ідхилення': np.float64(13.27462218141842), 'коеф. варіації': np.float64(1.3016104307
741885)}

--- ФЕРИТ1 (відношень)
    {'непорожніх': 2, 'унікальних': 2, 'частоти': {839.0: 1, 271.1: 1}, 'мода': [27
1.1, 839.0], 'медіана': np.float64(555.05), 'q25': np.float64(413.07500000000005),
'q75': np.float64(697.025), 'середнє': np.float64(555.05), 'ст. відхилення': np.floa

```
t64(401.5659410358403), 'коеф. варіації': np.float64(0.723477057987281)}
```

Етап 3. Три безглузді числа

`df.describe()` порахує статистики для всього, що схоже на число. Частина цих чисел не має жодного змісту.

Знайдіть **щонайменше три** такі числа у своєму наборі: обчисліть їх, а потім поясніть, чому кожне з них безглузде.

In [34]:
```
df[МОЇ].describe(include='all').T
```

Out[34]:

	count	unique	top	freq	mean	min	25%	50%
Телефон	120	120	0958469788 дружина Ганна	1	NaN	NaN	NaN	NaN
Супутній	115	91	ІХС ДК ГХст2	7	NaN	NaN	NaN	NaN
ЛН	121	6	II-III	59	NaN	NaN	NaN	NaN
Дата розтину	61	NaN	NaN	NaN	2022-04-06 13:22:37.377049088	2021-01-06 00:00:00	2022-03-29 00:00:00	2022-04-23 00:00:00
КТ	44.0	26.0	0.3	6.0	NaN	NaN	NaN	NaN
Фібрин1	115.0	87.0	6.0	6.0	NaN	NaN	NaN	NaN
Сечов2	102.0	66.0	4.9	4.0	NaN	NaN	NaN	NaN
ФЕРИТ1	2.0	NaN	NaN	NaN	555.05	271.1	413.075	555.05

In [35]:
```
БЕЗГЛУЗДІ = [
    # ('стовпець', 'яка статистика', значення, 'чому це число нічого не означає'),
    ('Телефон', 'mean, min, max, std, проміжні', np.nan , 'Номер телефону є набором
    ('ЛН', 'mean, min, max, std, проміжні', np.nan , 'Хоча і можна вважати числом (
    ('Дата розтину', 'mean', '2022-04-06 13:22:37.377049088' , 'Середнє від дати не
    ('КТ', 'mean, min, max, std, проміжні', np.nan , 'Хоча це і є відсотки, вони не
    ('ФЕРИТ1', 'std', 401.565941, 'Лише 2 спостереження не оцінює розкид популяції.
]

assert len(БЕЗГЛУЗДІ) >= 3, 'Потрібно щонайменше три приклади'
pd.DataFrame(БЕЗГЛУЗДІ, columns=['Стовпець', 'Статистика', 'Значення', 'Чому безглу
```

Out[35]:

	Стовпець	Статистика	Значення	Чому безглуздe
0	Телефон	mean, min, max, std, проміжні	NaN	Номер телефону є набором цифр, не числом
1	ЛН	mean, min, max, std, проміжні	NaN	Хоча і можна вважати числом (перша, друга і тд. стадії),...
2	Дата розтину	mean	2022-04-06 13:22:37.377049088	Середнє від дати не надає жодної інформації про розтини,...
3	КТ	mean, min, max, std, проміжні	NaN	Хоча це і є відсотки, вони не унормовані, тобто дії над ...
4	ФЕРИТ1	std	401.565941	Лише 2 спостереження не оцінює розкид популяції.

Етап 4. Міра зв'язку для вашої пари

Для двох змінних вашого варіанта треба оцінити зв'язок. Міру обирає **пара шкал**, а не зручність:

Поєднання шкал	Міра
відношень × відношень	кореляція Пірсона
порядкова × порядкова	рангова кореляція Спірмена
номінальна × номінальна	χ^2 та коефіцієнт Крамера (V)
відношень × бінарна номінальна	точковий бісеріальний коефіцієнт
номінальна × порядкова	коефіцієнт Крамера (V)

Обґрунтуйте вибір, обчисліть міру й поясніть результат. Окремо покажіть, **що станеться**, якщо застосувати Пірсона там, де він недопустимий, — і чому отримане число не можна інтерпретувати.

In [36]:
```
A, B = B['пара']
print('Ваша пара:', A, '×', B)
print()
print(f'{A}: шкала —', ПАСПОРТ.get(A, ('не у вашому списку',))[0] or '(визначте сам
print(f'{B}: шкала —', ПАСПОРТ.get(B, ('не у вашому списку',))[0] or '(визначте сам
print()
print(df[[A, B]].head(6).to_string())
```

```
Ваша пара: ЛН × помер/жив

ЛН: шкала — порядкова
помер/жив: шкала — не у вашому списку

       ЛН  помер/жив
0  III-IV          1
1  II-III          2
2      II          2
3  III-IV          2
4  II-III          2
5  II-III          1
```

In [37]:
```python
шкала_А = 'номінальна'
ОБРАНА_МІРА = 'коефіцієнт Крамера (V)'        # напишіть назву міри
ЧОМУ_САМЕ_ВОНА = 'ЛН за шкалою є порядковою, а помер/живий - номінальною (тільки по

assert ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40, 'Заповніть обидва поля'

# ваш код: обчисліть обрану міру
from scipy.stats import chi2_contingency

таб = pd.crosstab(df[A].map(нормалізуй_лн), df[B])
print(таб)

xi2, p, _, очік = chi2_contingency(таб, correction=False)
n = таб.values.sum()
V = np.sqrt(xi2 / (n * (min(таб.shape) - 1)))

print(f'χ² = {xi2:.2f}, p = {p:.4f}, n = {n}')
print(f'V Крамера = {V:.3f}')
print(f'найменша очікувана частота: {очік.min():.2f}')
```

```
помер/жив   1   2
ЛН
I           0  12
I-II        0   9
II          0  21
II-III     49  10
III        11   6
III-IV      1   2
χ² = 69.58, p = 0.0000, n = 121
V Крамера = 0.758
найменша очікувана частота: 1.49
```

V Крамера = 0,758. Це сильний зв'язок. Не можна ствердити, що смертність залежить саме від ступеню ЛН, однак випадковістю це теж не є.

In [38]:
```python
# Тепер — контрприклад: застосуйте кореляцію Пірсона незалежно від шкал
# і поясніть, чому отримане число не можна використовувати.
ранги = {'I': 1, 'I-II': 2, 'II': 3, 'II-III': 4, 'III': 5, 'III-IV': 6}
x = df[A].map(нормалізуй_лн).map(ранги)
y = df[B]

ok = x.notna() & y.notna()
x, y = x[ok], y[ok]
```

```
r1 = np.corrcoef(x, y)[0, 1]
r2 = np.corrcoef(x, 3 - y)[0, 1]
r3 = np.corrcoef(x.map(lambda k: k**2), y)[0, 1]

print(f'Пірсон, початкове кодування:        {r1:+.3f}')
print(f'Пірсон, мітки помер/жив поміняли:   {r2:+.3f}')
print(f'Пірсон, ранги ЛН піднесли до квадр.: {r3:+.3f}')
```

```
Пірсон, початкове кодування:        -0.544
Пірсон, мітки помер/жив поміняли:   +0.544
Пірсон, ранги ЛН піднесли до квадр.: -0.495
```

Пірсон дає |r| ≈ 0,5, тобто «середній зв'язок», тоді як V Крамера дає 0,758, тобто сильний. Пірсон занижує зв'язок, бо шукає пряму лінію, а реальна залежність має форму сходинки з немонотонним хвостом. Це додатковий аргумент проти Пірсона: він не тільки довільний за знаком, а й неадекватний за формою залежності.

Етап 5. Підготовка змінних до моделі

Шкала визначає не лише статистику, а й спосіб кодування.

Шкала	Як готують до моделі
Номінальна	one-hot кодування; порядок категорій не вводять
Порядкова	впорядкована категорія або цілі коди із **заданим** порядком
Інтервальна	стандартизація; для дат — перехід до тривалостей
Відношень	нормалізація або стандартизація; можливе логарифмування
Ідентифікатор	у модель не беруть узагалі

Для кожного свого стовпця вкажіть спосіб підготовки — і **виконайте його** щонайменше для трьох стовпців різних шкал.

In [39]:
```
ПІДГОТОВКА = {
    'Телефон':      'не беремо в модель: ідентифікатор, не величина',
    'Супутній':     'групуємо за ключовими словами, потім one-hot: порядок категорі
    'ЛН':           'ціле кодування 1..6 із заданим порядком: порядок відомий, відс
    'Дата розтину': 'перехід до тривалості в днях від найранішої дати, потім станда
    'КТ':           'розпарсити в частку 0..1, потім нормалізація',
    'Фібрин1':      'перетворити на число, log1p проти правого хвоста, потім станда
    'Сечов2':       'перетворити на число, log1p, стандартизація',
    'ФЕРИТ1':       'не беремо в модель: лише 2 значення',
}
for c in МОЇ:
    ПІДГОТОВКА.setdefault(c, '')
```

```
pd.DataFrame([(c, ПАСПОРТ[c][0], ПІДГОТОВКА[c]) for c in МОЇ],
             columns=['Стовпець', 'Шкала', 'Як готуємо'])
```

Out[39]:

	Стовпець	Шкала	Як готуємо
0	Телефон	ідентифікатор	не беремо в модель: ідентифікатор, не величина
1	Супутній	номінальна	групуємо за ключовими словами, потім one-hot: порядок ка...
2	ЛН	порядкова	ціле кодування 1..6 із заданим порядком: порядок відомий...
3	Дата розтину	інтервальна	перехід до тривалості в днях від найранішої дати, потім ...
4	КТ	відношень	розпарсити в частку 0..1, потім нормалізація
5	Фібрин1	відношень	перетворити на число, log1p проти правого хвоста, потім ...
6	Сечов2	відношень	перетворити на число, log1p, стандартизація
7	ФЕРИТ1	відношень	не беремо в модель: лише 2 значення

In [40]:

```
# ваш код: реалізуйте підготовку для трьох стовпців різних шкал
from sklearn.preprocessing import StandardScaler

порядок = ['I', 'I-II', 'II', 'II-III', 'III', 'III-IV']

лн = df['ЛН'].map(нормалізуй_лн)
лн_кат = pd.Categorical(лн, categories=порядок, ordered=True)
лн_код = pd.Series(лн_кат.codes, index=df.index).replace(-1, np.nan) + 1
print('ЛН невідомих:', int(лн_код.isna().sum()))
print(лн_код.value_counts().sort_index())

def група(t):
    if pd.isna(t): return 'невідомо'
    t = str(t).upper().replace('I', 'I')
    if 'ІХС' in t or 'ІХС' in t or 'ИБС' in t: return 'ІХС'
    if 'ЦД' in t or 'ДІАБЕТ' in t or 'DM' in t: return 'ЦД'
    if 'ГХ' in t or 'ГІПЕРТОН' in t:            return 'ГХ'
    return 'інше'

супутні = df['Супутній'].map(група)
супутні_oh = pd.get_dummies(супутні, prefix='супутній')
print(супутні.value_counts())
print(супутні_oh.head())

фібрин = pd.to_numeric(df['Фібрин1'], errors='coerce')
print('Фібрин1 не розпізнано:', int(фібрин.isna().sum() - df['Фібрин1'].isna().sum(
ф_log = np.log1p(фібрин)
ok = ф_log.notna()
ф_z = pd.Series(np.nan, index=df.index)
ф_z[ok] = StandardScaler().fit_transform(ф_log[ok].to_frame()).ravel()
```

```
print(f'до: mean={фібрин.mean():.2f}, std={фібрин.std():.2f}')
print(f'після: mean={ф_z.mean():.3f}, std={ф_z.std():.3f}')
```

```
ЛН невідомих: 0
1    12
2     9
3    21
4    59
5    17
6     3
Name: count, dtype: int64
Супутній
ГХ          50
інше        37
ЦД          28
невідомо     6
Name: count, dtype: int64
   супутній_ГХ  супутній_ЦД  супутній_невідомо  супутній_інше
0        False        False              False           True
1        False         True              False          False
2         True        False              False          False
3        False         True              False          False
4         True        False              False          False
Фібрин1 не розпізнано: 1
до: mean=5.05, std=1.95
після: mean=0.000, std=1.004
```

Перед нормалізацією обов'язково перевірте варіативність. Стовпець, у якому всі значення однакові, дасть нуль у знаменнику — і мовчазний `NaN` замість помилки.

In [41]:
```
for c in МОЇ:
    з = pd.to_numeric(df[c], errors='coerce').dropna()
    if len(з) and з.nunique() == 1:
        print(f'УВАГА: {c} — сталий стовпець, нормалізація дасть ділення на нуль')
    elif len(з) and з.max() == з.min():
        print(f'УВАГА: {c} — max дорівнює min')
print('Перевірку варіативності виконано.')
```

```
Перевірку варіативності виконано.
```

In [42]:
```
# --- САМОПЕРЕВІРКА 2 ---
assert all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in МОЇ), \
    'Для кожного стовпця вкажіть спосіб підготовки'
assert len(БЕЗГЛУЗДІ) >= 3, 'Етап 3 не завершено'
print('Самоперевірка 2 пройдена.')
```

```
Самоперевірка 2 пройдена.
```

Етап 6. Виправлення чужого аналізу

Відкрийте файл **`ЛР3_помилковий_аналіз.ipynb`**. Це звіт, який виконується без жодної помилки й містить десять хибних місць.

Для кожного з десяти заповніть рядок нижче:

- **розділ** — номер розділу звіту;
- **що не так** — яка шкала порушена або яке припущення хибне;
- **чому число неправильне** — що саме воно означає насправді;
- **як правильно** — коректний варіант або обґрунтована відмова від показника.

In [43]:
```
ВИПРАВЛЕННЯ = [
    # (розділ, 'що не так', 'чому число неправильне', 'як правильно'),
    ('1. Результат лікування',
     'Середнє від номінальної бінарної ознаки (коди 1 і 2 є лише мітками).',
     'Число 1,50 залежить від довільних кодів: з мітками 0/1 було б 0,50. «Рівно по
     'Рахувати частоти й частки: 61 з кодом 1 (50,4 %) і 60 з кодом 2 (49,6 %). Сер

    ('2. Стать',
     'Дані непридатні: одна номінальна ознака записана чотирма написаннями (ж, жін,
     '«Чотири статі» є артефактом введення. Насправді дві категорії, а розподіл 56/
     'Привести до єдиного запису (ж+жін = 75, ч+чол = 46) і лише потім рахувати час

    ('3. Ступінь КТ',
     'Порядкова шкала: середнє від кодів, які присвоєно за алфавітом на брудних міт
     'sort_index() упорядковує літери, а не тяжкість: «найлегшим» став «важкий». Се
     'Нормалізувати мітки, задати порядок вручну (легкий < середній < важкий < вкра

    ('4. Обсяг ураження КТ',
     'Дані непридатні: to_numeric(errors="coerce") мовчки відкинув рядкові значення
     'Із 44 заповнених значень 17 рядкових, тож 39,6 % отримано приблизно на 27 пац
     'Розпарсити діапазони (середина інтервалу), перевести все в єдині одиниці і за

    ('5. Сатурація',
     'Дані непридатні: у стовпці є мінімум 0,9 %, що фізіологічно неможливо (помилк
     'Викид тягне середнє донизу (82,05 проти медіани 84,0), а висновок про «більші
     'Знайти й виправити/виключити неможливі значення, порахувати медіану та кварти

    ('6. Дати госпіталізації',
     'Коефіцієнт варіації для дат: інтервальна шкала має умовний нуль, а CV вимагає
     'CV = σ/середнє залежить від точки відліку. Для тих самих дат він змінюється в
     'Для дат допустимі різниці: σ у днях, розмах, кількість надходжень по тижнях/м

    ('7. Стать і результат',
     'Номінальні ознаки: «лінійний зв’язок» і знак кореляції не мають змісту, а 0,1
     'Для двох бінарних ознак r дорівнює ϕ. Тоді χ² = n·ϕ² ≈ 3,8 і p ≈ 0,05: зв’язо
     'Таблиця спряженості, χ² або Фішер, ϕ/V Крамера з довірчим інтервалом і чесним

    ('8. Нормалізація',
     'Вибір ознак за dtype (select_dtypes("number")), а не за шкалою: до мін-макс п
     'Масштабування лише для величин (інтервальна, відношень). Для кодів категорій
     'Відібрати стовпці за паспортом шкал, пропустити номінальні й ідентифікатори,

    ('9. Очищення пропусків',
     'Дані непридатні: dropna() видаляє рядок при будь-якому пропуску, а в 77 ознак
     'Результат 0 рядків, але текст жорстко пише «повністю заповнений, придатний дл
     'Спершу оцінити частку пропусків по стовпцях, прибрати порожні/майже порожні,
```

```
    ('10. Рейтинг ознак',
     'Витік цілі: «Дата розтину» існує лише в тих, хто помер, а NaN після astype(in
     'r = 1,00 відображає не прогноз, а те, що розтин проводять після смерті (61 да
     'Виключити всі ознаки, відомі лише після результату, і вказувати n для кожної
]

assert len(ВИПРАВЛЕННЯ) == 10, f'Знайдено {len(ВИПРАВЛЕННЯ)} помилок із 10'
for p in ВИПРАВЛЕННЯ:
    assert len(p) == 4 and all(str(x).strip() for x in p), 'Заповніть усі чотири по
    assert len(str(p[2])) >= 30 and len(str(p[3])) >= 25, 'Пояснення закороткі'

pd.DataFrame(ВИПРАВЛЕННЯ, columns=['Розділ', 'Що не так', 'Чому число неправильне',
```

Out[43]:

	Розділ	Що не так	Чому число неправильне	Як правильно
0	1. Результат лікування	Середнє від номінальної бінарної ознаки (коди 1 і 2 є ли...	Число 1,50 залежить від довільних кодів: з мітками 0/1 б...	Рахувати частоти й частки: 61 з кодом 1 (50,4 %) і 60 з ...
1	2. Стать	Дані непридатні: одна номінальна ознака записана чотирма...	«Чотири статі» є артефактом введення. Насправді дві кате...	Привести до єдиного запису (ж+жін = 75, ч+чол = 46) і ли...
2	3. Ступінь КТ	Порядкова шкала: середнє від кодів, які присвоєно за алф...	sort_index() упорядковує літери, а не тяжкість: «найлегш...	Нормалізувати мітки, задати порядок вручну (легкий < сер...
3	4. Обсяг ураження КТ	Дані непридатні: to_numeric(errors="coerce") мовчки відк...	Із 44 заповнених значень 17 рядкових, тож 39,6 % отриман...	Розпарсити діапазони (середина інтервалу), перевести все...
4	5. Сатурація	Дані непридатні: у стовпці є мінімум 0,9 %, що фізіологі...	Викид тягне середнє донизу (82,05 проти медіани 84,0), а...	Знайти й виправити/ виключити неможливі значення, порахув...
5	6. Дати госпіталізації	Коефіцієнт варіації для дат: інтервальна шкала має умовн...	CV = σ/середнє залежить від точки відліку. Для тих самих...	Для дат допустимі різниці: σ у днях, розмах, кількість н...
6	7. Стать і результат	Номінальні ознаки: «лінійний зв'язок» і знак кореляції н...	Для двох бінарних ознак r дорівнює φ. Тоді $\chi^2 = n \cdot \varphi^2 \approx 3$...	Таблиця спряженості, χ^2 або Фішер, φ/V Крамера з довірчи...
7	8. Нормалізація	Вибір ознак за dtype (select_dtypes("number")), а не за ...	Масштабування лише для величин (інтервальна, відношень)....	Відібрати стовпці за паспортом шкал, пропустити номіналь...
8	9. Очищення пропусків	Дані непридатні: dropna() видаляє рядок при будь-якому п...	Результат 0 рядків, але текст жорстко пише «повністю зап...	Спершу оцінити частку пропусків по стовпцях, прибрати по...
9	10. Рейтинг ознак	Витік цілі: «Дата розтину» існує лише в тих, хто помер, ...	r = 1,00 відображає не прогноз, а те, що розтин проводят...	Виключити всі ознаки, відомі лише після результату, і вк...

Виправте щонайменше три помилки в коді

Оберіть три з десяти та покажіть правильне обчислення поруч із неправильним.

In [44]:
```
# ваш код: три правильні обчислення замість хибних
print('Розділ 1')
print('ХИБНО:', df['помер/жив'].mean())
print('ПРАВИЛЬНО:')
print(df['помер/жив'].value_counts())
print((df['помер/жив'].value_counts(normalize=True) * 100).round(1))
print('-'*35, '\n')

print('Розділ 3')
порядок = ['легкий', 'середній', 'важкий', 'вкрай важкий', 'критичний']
мапа = {'легка': 'легкий', 'сердній': 'середній',
        'серед ступ': 'середній', 'серед ступеня': 'середній'}

мітки = (df['ступінь КТ'].dropna().astype(str)
         .str.strip().str.lower().str.replace(r'\s+', ' ', regex=True)
         .replace(мапа))
print('Невідомі мітки:', sorted(set(мітки) - set(порядок)))

коди = pd.Categorical(мітки, categories=порядок, ordered=True).codes
коди = pd.Series(коди)[коди >= 0]
for q in (0.25, 0.5, 0.75):
    print(f'квантиль {q}:', порядок[int(np.quantile(коди, q, method="lower"))])
print(pd.Series(pd.Categorical(мітки, categories=порядок, ordered=True)).value_coun
print('-'*35, '\n')

print('Розділ 6')
дати = pd.to_datetime(df['Поступлення'], errors='coerce').dropna()
for відлік in ['1970-01-01', '2021-01-01']:
    x = (дати - pd.Timestamp(відлік)).dt.days
    print(f'ХИБНО: CV від {відлік} = {100*x.std()/x.mean():.2f} %')
print('ПРАВИЛЬНО:')
print('σ у днях :', round((дати - дати.min()).dt.days.std(), 1))
print('розмах   :', дати.min().date(), '—', дати.max().date())
print(дати.dt.to_period('M').value_counts().sort_index())

print('ХИБНО: NaT ->', pd.Series(pd.to_datetime([None])).astype('int64')[0])
print('Є дата розтину:', df['Дата розтину'].notna().sum(),
      '| код 1 (помер):', (df['помер/жив'] == 1).sum())
print(pd.crosstab(df['Дата розтину'].notna(), df['помер/жив']))
print('-'*35, '\n')
```

```
Розділ 1
ХИБНО: 1.4958677685950412
ПРАВИЛЬНО:
помер/жив
1    61
2    60
Name: count, dtype: int64
помер/жив
1    50.4
2    49.6
Name: proportion, dtype: float64
----------------------------------

Розділ 3
Невідомі мітки: []
квантиль 0.25: середній
квантиль 0.5: середній
квантиль 0.75: важкий
легкий           7
середній        18
важкий          10
вкрай важкий     4
критичний        3
Name: count, dtype: int64
----------------------------------

Розділ 6
ХИБНО: CV від 1970-01-01 = 0.59 %
ХИБНО: CV від 2021-01-01 = 30.04 %
ПРАВИЛЬНО:
σ у днях : 113.0
розмах   : 2021-02-25 — 2022-06-03
Поступлення
2021-02     1
2021-04     2
2021-05     4
2021-06     3
2021-07     2
2021-08     4
2021-09     9
2021-10     4
2021-11    11
2021-12     7
2022-01     3
2022-02    10
2022-03    18
2022-04    30
2022-05    11
2022-06     1
Freq: M, Name: count, dtype: int64
ХИБНО: NaT -> -9223372036854775808
Є дата розтину: 61 | код 1 (помер): 61
помер/жив      1   2
Дата розтину
False          0  60
True          61   0
```

```
----------------------------------
```

Етап 7. Висновки та індивідуальне питання

In [45]:
```
ВИСНОВКИ = [
    'Серед восьми стовпців лише Фібрин1, Сечов2, ФЕРИТ1 і КТ є величинами зі шкалою

    'Якість даних обмежує аналіз: у КТ заповнено лише 44 значення зі 121 і до того

    'Між ступенем ЛН і результатом лікування виявлено сильний зв’язок (χ² = 69,6; V
]
assert len(ВИСНОВКИ) >= 3 and all(len(в) >= 60 for в in ВИСНОВКИ), \
    'Потрібні три змістовні висновки'
for i, в in enumerate(ВИСНОВКИ, 1):
    print(f'{i}. {в}')
```

```
1. Серед восьми стовпців лише Фібрин1, Сечов2, ФЕРИТ1 і КТ є величинами зі шкалою ві
дношень, а Телефон є ідентифікатором, Супутній номінальним, ЛН порядковим, Дата розт
ину інтервальним, тому до них не можна застосовувати однакові статистики лише на під
ставі того, що pandas читає частину з них як числа
2. Якість даних обмежує аналіз: у КТ заповнено лише 44 значення зі 121 і до того ж у
змішаному форматі (27 чисел і 17 діапазонів на кшталт «20-30%»), у ФЕРИТ1 лише 2 зна
чення, а у Фібрин1 та Сечов2 трапляється по одному рядковому значенню серед чисел, т
ож їхні середні й відхилення без попереднього очищення ненадійні
3. Між ступенем ЛН і результатом лікування виявлено сильний зв’язок (χ² = 69,6; V Кр
амера = 0,76; n = 121): усі 42 пацієнти зі ступенями I, I-II та II мають код 2, а пр
и II-III код 1 мають 49 із 59 (83 %), однак мінімальна очікувана частота становить л
ише 1,49, тому точне значення V слід вважати орієнтовним
```

In [46]:
```
print('ВАШЕ ПИТАННЯ:'); print(B['питання']); print()
ВІДПОВІДЬ = 'Є такі три способи перетворити його на числові ознаки: 1. Розділити на
assert len(ВІДПОВІДЬ.strip()) >= 200, 'Відповідь має бути розгорнутою (від 200 симв
print(ВІДПОВІДЬ)
```

```
ВАШЕ ПИТАННЯ:
Стовпець «АТ пост» містить значення на кшталт «140/100». Запропонуйте три способи пе
ретворити його на числові ознаки та обґрунтуйте, який із них візьмете в модель.

Є такі три способи перетворити його на числові ознаки: 1. Розділити на два числа: си
столічний (САТ) і діастолічний (ДАТ). Це найпряміший спосіб: «140/100» стає двома оз
наками, 140 і 100. Обидві величини вимірюються в мм рт. ст. зі шкалою відношень, нул
ь означає відсутність тиску. Нічого не втрачається, а інтерпретація зрозуміла лікар
ю. 2. Похідні показники: пульсовий тиск і середній артеріальний тиск. Пульсовий тиск
(ПТ) дорівнює САТ – ДАТ, а середній (СрАТ) дорівнює ДАТ + (САТ – ДАТ)/3. Обидва мают
ь фізіологічний зміст: ПТ відображає жорсткість судин і ударний обсяг, СрАТ відображ
ає перфузію органів. Але вони обчислюються з тих самих двох чисел, тож нової інформа
ції не додають, лише інакше її впаковують. 3. Клінічні категорії. Наприклад: гіпотен
зія, норма, гіпертензія 1, 2, 3 ступеня за порогами. Це порядкова ознака, її кодують
цілими числами із заданим порядком. Шкала знижується з відношень до порядкової, тому
частина інформації втрачається.
У модель моїм вибором було би взяти перший варіант - дані не втрачаються, інші значе
ння легко обраховуються з них самих.
```

Етап 8. Декларація про використання інструментів ШІ

Користуватися мовними моделями дозволено. Це нормальна інженерна практика.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок свого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці.

Для кожного етапу оберіть одне з формулювань:

- `'ні'` — інструментами ШІ не користувався
- `'синтаксис'` — питав про назву функції або синтаксис, код писав сам
- `'код, перевірено'` — код згенеровано, я його прочитав, перевірив і розумію
- `'текст, перероблено'` — згенеровано чернетку тексту, яку я переписав по суті
- `'текст, як є'` — згенерований текст залишено майже без змін

In [47]:
```
ДЕКЛАРАЦІЯ = {
    'етап 1 — паспорт змінних':        'текст, як є',
    'етап 2 — допустимі статистики':   'текст, як є',
    'етап 3 — безглузді числа':        'текст, як є',
    'етап 4 — міра зв’язку':           'текст, як є',
    'етап 5 — підготовка до моделі':   'текст, як є',
    'етап 6 — виправлення аналізу':    'текст, як є',
    'етап 7 — висновки й відповідь':   'текст, як є',
```

```
}

ЩО_САМЕ_Я_ПЕРЕВІРИВ = 'Увесь код було переглянуто, а результато перевірено самотужк
ПІДТВЕРДЖУЮ = True     # я можу пояснити кожен рядок свого коду
                       # і внести в нього зміни на вимогу під час захисту
```

In [48]:
```
# --- ФІНАЛЬНА САМОПЕРЕВІРКА ---
ФОРМУЛЮВАННЯ = {'ні', 'синтаксис', 'код, перевірено', 'текст, перероблено', 'текст,

перевірки = {
    'заповнено титульні поля':        bool(ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР),
    'етап 1: паспорт із 8 стовпців':  all(ПАСПОРТ[c][0] and ПАСПОРТ[c][1] for c in
    'етап 3: три безглузді числа':    len(БЕЗГЛУЗДІ) >= 3,
    'етап 4: міру обрано й пояснено': bool(ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 4
    'етап 5: підготовку описано':     all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in
    'етап 6: знайдено 10 помилок':    len(ВИПРАВЛЕННЯ) == 10,
    'етап 7: три висновки':           len(ВИСНОВКИ) >= 3,
    'етап 7: відповідь на питання':   len(ВІДПОВІДЬ.strip()) >= 200,
    'декларацію заповнено':           all(v in ФОРМУЛЮВАННЯ for v in ДЕКЛАРАЦІЯ.val
    'опис перевірки ≥ 120 символів':  len(ЩО_САМЕ_Я_ПЕРЕВІРИВ.strip()) >= 120,
    'підтвердження авторства':        ПІДТВЕРДЖУЮ is True,
}

print('ЧЕК-ЛИСТ ГОТОВНОСТІ')
print('=' * 52)
for назва, ок in перевірки.items():
    print(('  ГОТОВО     ' if ок else '  НЕ ГОТОВО ') + назва)
print('=' * 52)

assert all(перевірки.values()), 'Робота не готова до здачі — див. чек-лист вище'
print()
print(f'Робота варіанта {В["варіант"]} готова до захисту.')
print(f'{ПРІЗВИЩЕ_ІМЯ}, {ГРУПА}')
```

```
ЧЕК-ЛИСТ ГОТОВНОСТІ
====================================================
  ГОТОВО     заповнено титульні поля
  ГОТОВО     етап 1: паспорт із 8 стовпців
  ГОТОВО     етап 3: три безглузді числа
  ГОТОВО     етап 4: міру обрано й пояснено
  ГОТОВО     етап 5: підготовку описано
  ГОТОВО     етап 6: знайдено 10 помилок
  ГОТОВО     етап 7: три висновки
  ГОТОВО     етап 7: відповідь на питання
  ГОТОВО     декларацію заповнено
  ГОТОВО     опис перевірки ≥ 120 символів
  ГОТОВО     підтвердження авторства
====================================================

Робота варіанта 2 готова до захисту.
Бугай Софія, ШІ-34
```

Перед здачею

Виконайте **Kernel → Restart & Run All**. Ноутбук має пройти згори донизу без жодної помилки — це перше, що перевіряється на захисті.